Pipeline appliqué au diagnostic du cancer du sein

Rapport Technique

Clara Pierreuse (SIEF) - Vladie Werber (ARM)

Année Universitaire 2025/2026

Master Monnaie Banque Finance Assurance

Parcours Système d'information économique et financier / Analyse des risques de marchés

Université de Montpellier

Sous la supervision de : Monsieur Gonthier Lucas

Table des matières

Introduction **3**
1. Description des données **3**
2. Analyse exploratoire des données (EDA) **4**
2.1 Vérifications structurelles 5
2.2 Distribution de la variable cible 5
2.3 Analyse des variables numériques 6
2.4 Conclusion de l'EDA 7
3. Cadre méthodologique général **8**
3.1 Découpage des données et intégrité expérimentale 8
3.2 Prévention du Data Leakage 8
3.3 Validation croisée stratifiée 9
3.4 Métriques d'évaluation 9
4. Modèles classiques étudiés **10**
4.1 Régression logistique 10
4.2 Arbre de décision 11
4.3 Forêt aléatoire 11
5. Validation croisée et comparaison approfondie des performances **11**
6. Approche d'ensemble : Soft Voting **12**
7. Optimisation des hyperparamètres **12**
8. Modèle de Deep Learning (MLP) **13**
9. Évaluation finale sur le jeu de test **13**
10. Discussion critique **14**
11. Reproductibilité et bonnes pratiques **15**
Conclusion générale **16**

Introduction

Le cancer du sein constitue l'un des cancers les plus fréquents chez les femmes à l'échelle mondiale. La capacité à distinguer précocement une tumeur maligne d'une tumeur bénigne représente un enjeu clinique majeur. Une erreur de classification, en particulier un faux négatif (classer une tumeur maligne comme bénigne), peut retarder la prise en charge thérapeutique et avoir des conséquences graves pour la patiente. À l'inverse, un faux positif peut entraîner des examens invasifs inutiles et un stress important.

Dans ce contexte, l'objectif de ce projet est de construire un pipeline complet de classification supervisée permettant de prédire le caractère malin (M) ou bénin (B) d'une tumeur mammaire à partir de caractéristiques morphologiques extraites d'images de noyaux cellulaires issues de biopsies. Le travail repose sur le Breast Cancer Wisconsin Dataset, jeu de données de référence largement utilisé dans la littérature pour évaluer et comparer des algorithmes de machine learning.

Cependant, l'enjeu du projet ne se limite pas à la recherche de la meilleure performance brute. L'objectif principal est méthodologique : mettre en place une démarche scientifique rigoureuse respectant les standards actuels du machine learning. Cela implique :

Une séparation stricte entre analyse exploratoire et phase de modélisation,
L'absence totale de fuite d'information,
L'intégration du preprocessing dans un pipeline reproductible,
L'utilisation d'une validation croisée stratifiée,
Une évaluation finale sur un jeu de test strictement indépendant.

Dans un contexte médical, toutes les erreurs n'ont pas le même poids. Ainsi, l'analyse ne se limite pas à l'accuracy. Une attention particulière est portée au recall de la classe maligne, au F1-score, à la ROC-AUC ainsi qu'à la PR-AUC, afin d'obtenir une vision complète et nuancée des performances. Cette approche permet d'évaluer non seulement la précision globale du modèle, mais aussi sa capacité à détecter correctement les cas à risque.

Ce projet vise donc à concilier performance prédictive, interprétabilité, rigueur méthodologique et reproductibilité, afin de produire un pipeline robuste et scientifiquement justifiable.

1. Description des données

Le dataset utilisé contient 569 observations, chacune correspondant à une tumeur mammaire analysée à partir d'images de noyaux cellulaires issues de biopsies. Chaque observation est décrite par 30 variables explicatives numériques, ainsi qu'une variable cible binaire nommée `diagnosis`, indiquant si la tumeur est maligne (M) ou bénigne (B).

Les variables explicatives mesurent différentes caractéristiques morphologiques des noyaux cellulaires, telles que :

- le rayon (radius),
- la texture (texture),
- le périmètre (perimeter),
- l'aire (area),

- la compacité,
- la concavité,
- la symétrie,
- la dimension fractale.

Pour chacune de ces caractéristiques, trois mesures sont généralement disponibles :

- la valeur moyenne (mean),
- l'erreur standard (se),
- la valeur maximale observée (worst).

Cette structuration induit naturellement des corrélations élevées entre certaines variables. Par exemple, le rayon, le périmètre et l'aire sont mathématiquement liés, ce qui génère une redondance d'information. L'analyse de la matrice de corrélation confirme l'existence de groupes de variables fortement corrélées (coefficients supérieurs à 0.8 ou 0.9 dans certains cas). Cette multicolinéarité peut influencer la stabilité des modèles linéaires, notamment la régression logistique, bien qu'elle soit moins problématique pour les modèles basés sur des arbres.

La distribution de la variable cible montre un **déséquilibre modéré des classes** :

- Environ 63 % de tumeurs bénignes,
- Environ 37 % de tumeurs malignes.

Ce déséquilibre n'est pas extrême, mais il justifie l'utilisation d'un découpage stratifié lors du split train/test ainsi que dans la validation croisée. Cette précaution garantit que chaque sous-échantillon conserve une proportion représentative des deux classes.

Concernant la qualité des données :

- Aucune valeur manquante n'est présente dans la base,
- Aucun doublon significatif n'a été détecté,
- Aucune variable constante ou manifestement non informative (hormis l'identifiant) n'est conservée dans la modélisation.

Même si aucune valeur manquante n'est observée, un mécanisme d'imputation par la médiane est intégré dans le pipeline afin d'assurer la robustesse du modèle en cas d'application à des données externes.

Enfin, les variables présentent des ordres de grandeur hétérogènes (par exemple, l'aire et la dimension fractale). Cette disparité justifie l'application d'une **standardisation**, en particulier pour les modèles sensibles à l'échelle des variables (régression logistique et réseau de neurones).

Dans l'ensemble, le dataset est propre, cohérent et bien structuré pour un problème de classification binaire supervisée. Sa taille modérée impose toutefois une vigilance particulière en matière de validation et de contrôle du surapprentissage.

2. Analyse exploratoire des données (EDA)

Avant toute phase de modélisation, une analyse exploratoire des données a été réalisée afin de comprendre la structure du dataset, d'identifier d'éventuelles anomalies et de guider les choix méthodologiques ultérieurs.

2.1 Vérifications structurelles

La première étape a consisté à examiner :

- les dimensions du dataset,
- les types de variables,
- l'encodage correct de la variable cible,
- la présence éventuelle de valeurs manquantes ou de doublons.

Aucune anomalie structurelle majeure n'a été détectée. La variable cible `diagnosis` contient uniquement deux modalités (M et B), cohérentes avec un problème de classification binaire. L'absence de valeurs manquantes simplifie l'analyse, bien qu'un mécanisme d'imputation soit maintenu dans le pipeline pour garantir la robustesse.

Indicateur	Description	Valeur
Taille de l'échantillon	Nombre total d'observations	569
Dimension des données	Nombre total de variables	32
Variables explicatives	Variables numériques continues	30
Variable cible	Diagnostic binaire (M = Maligne, B = Bénigne)	1
Répartition classe B	Tumeurs bénignes	357 (62,7 %)
Répartition classe M	Tumeurs malignes	212 (37,3 %)
Valeurs manquantes	Données absentes	0
Doublons	Lignes dupliquées	0

2.2 Distribution de la variable cible

L'étude de la distribution des classes confirme un déséquilibre modéré. Bien que non critique, ce déséquilibre justifie :

- l'utilisation d'un split stratifié,
- une validation croisée stratifiée,
- l'analyse de métriques adaptées (recall, PR-AUC).

Dans un contexte médical, le recall de la classe maligne est particulièrement crucial. Un modèle performant doit minimiser les faux négatifs.

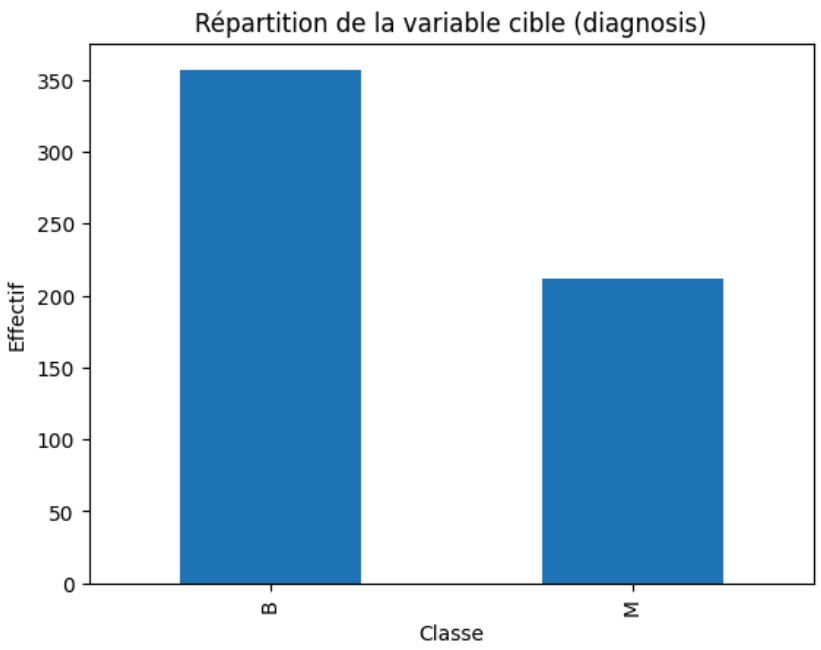

2.3 Analyse des variables numériques

L'analyse des distributions met en évidence des différences notables entre tumeurs malignes et bénignes. Certaines variables, comme `radius_mean`, `area_mean` ou `perimeter_mean`, présentent des valeurs systématiquement plus élevées pour les tumeurs malignes.

Cette observation suggère que les classes sont relativement bien séparables dans l'espace des variables, ce qui explique en partie les performances élevées obtenues par les modèles linéaires.

Des valeurs extrêmes sont également observées pour certaines variables. Elles ne semblent pas résulter d'erreurs de mesure, mais traduisent probablement la variabilité biologique réelle. La standardisation permettra d'éviter que ces différences d'échelle n'influencent excessivement les modèles sensibles à la magnitude des variables.

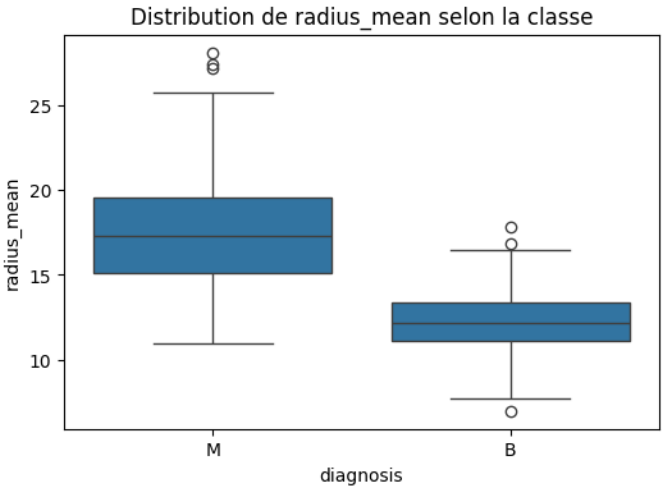

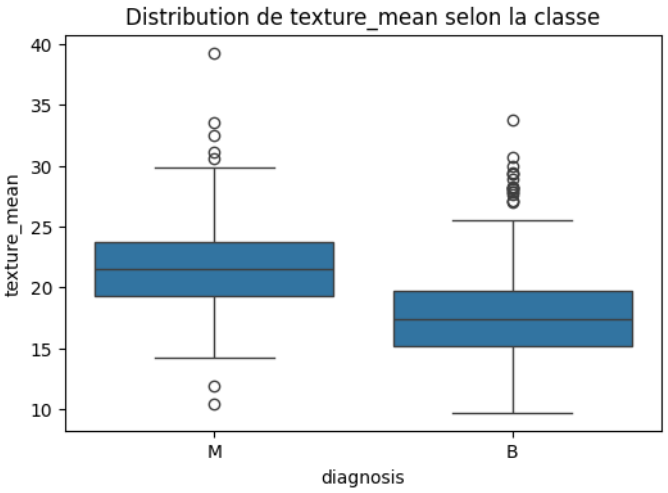

L'analyse de la matrice de corrélation révèle plusieurs groupes de variables fortement corrélées. En particulier, les variables liées aux dimensions géométriques (rayon, périmètre, aire) présentent des corrélations très élevées.

Cette redondance d'information peut avoir plusieurs implications :

- Pour les modèles linéaires : risque de coefficients instables.
- Pour les modèles d'arbres : impact plus limité.
- Pour le réseau de neurones : risque potentiel de redondance inutile.

Cependant, dans une logique prédictive plutôt qu'inférentielle, la multicolinéarité n'est pas nécessairement problématique si les performances sont stables en validation croisée.

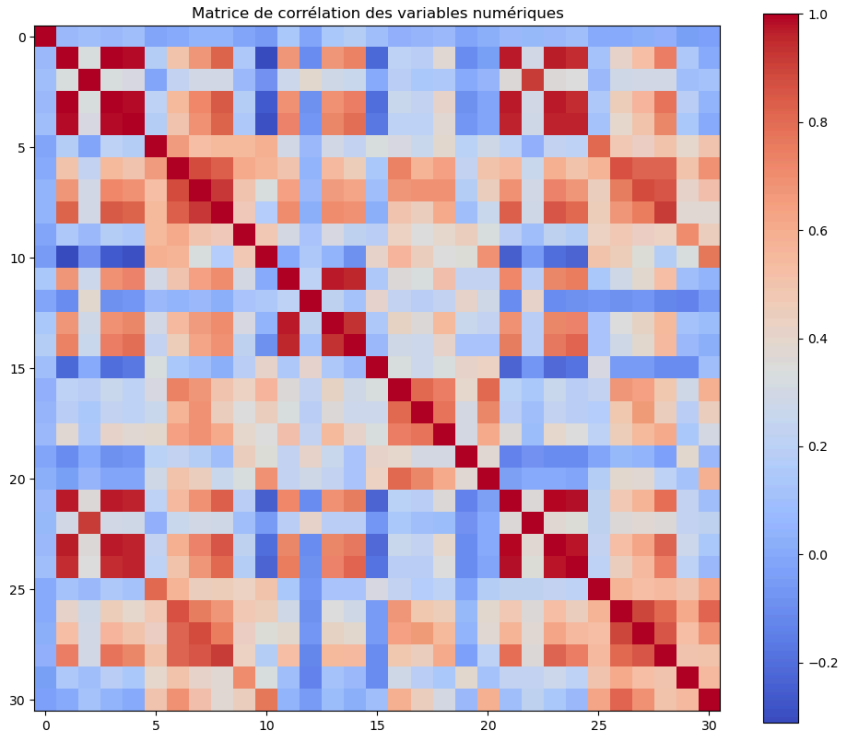

2.4 Conclusion de l'EDA

L'analyse exploratoire met en évidence plusieurs éléments clés :

- Dataset propre et exploitable.
- Séparabilité forte entre les classes.
- Corrélations importantes entre certaines variables.
- Hétérogénéité des échelles.
- Déséquilibre modéré des classes.

Ces constats justifient les choix méthodologiques adoptés par la suite :

- suppression de l'identifiant,
- encodage binaire de la cible,
- standardisation des variables,

- validation croisée stratifiée,
- priorité donnée à des métriques robustes.

Il est important de souligner que l'ensemble des transformations globales reste strictement confiné à la phase d'entraînement via un pipeline intégré, afin d'éviter toute fuite d'information.

3. Cadre méthodologique général

Cette section décrit le protocole expérimental mis en place afin de garantir une évaluation fiable, reproductible et exempte de biais. L'objectif n'est pas uniquement d'obtenir de bonnes performances, mais de s'assurer que ces performances reflètent une capacité réelle de généralisation.

3.1 Découpage des données et intégrité expérimentale

Le dataset est séparé en deux ensembles distincts :

80 % des observations pour l'entraînement
20 % des observations pour le test final

Le travail de découpage s'effectue de manière à garder la proportion originale de tumeurs cancéreuses et non cancéreuses dans les deux groupes. Cette méthode de stratification est cruciale dans une situation où les classes sont inégales, même de façon légère.

Le jeu de test est conservé strictement intact jusqu'à la fin du processus. Il n'est utilisé ni pour le réglage des hyperparamètres ni pour la sélection des modèles. Cette séparation stricte garantit que l'évaluation finale constitue une estimation hors-échantillon valide.

Une graine aléatoire fixe est utilisée pour assurer la reproductibilité complète du découpage et des résultats.

3.2 Prévention du Data Leakage

La prévention de la fuite d'information (data leakage) constitue un principe fondamental de la démarche expérimentale.

Toutes les transformations de preprocessing sont intégrées dans un pipeline appris exclusivement sur les données d'entraînement. Cela signifie que :

- Les paramètres d'imputation (médiane),
- Les paramètres de standardisation (moyenne et écart-type),

sont estimés uniquement sur le jeu d'entraînement, puis appliqués au jeu de validation ou de test.

Ainsi, aucune information issue du jeu de test n'influence l'apprentissage du modèle. Cette précaution est cruciale, car une fuite d'information peut artificiellement augmenter les performances mesurées.

3.3 Validation croisée stratifiée

Afin de comparer les modèles de manière robuste, une validation croisée stratifiée à cinq folds est appliquée sur le jeu d'entraînement.

Le principe est le suivant :

- Le jeu d'entraînement est divisé en cinq sous-ensembles.
- À chaque itération, quatre folds servent à l'entraînement.
- Le fold restant sert à l'évaluation.
- Le processus est répété cinq fois.

La stratification garantit le maintien de la proportion des classes dans chaque fold.

Pour chaque modèle, les métriques sont calculées sur chaque fold.

Modèle	ROC-AUC (mean)	F1-score (mean)	PR-AUC (mean)
Logistic Regression	0.9958	0.9640	0.9949
Decision Tree	0.9172	0.8962	0.8453
Random Forest	0.9877	0.9461	0.9865

Cette approche permet d'évaluer non seulement la performance moyenne, mais aussi la stabilité du modèle face aux variations d'échantillonnage.

3.4 Métriques d'évaluation

Dans un problème médical, l'accuracy seule est insuffisante.

Les métriques utilisées sont :

- Accuracy : proportion globale de classifications correctes.
- Recall (classe maligne) : capacité à détecter les cas à risque.
- F1-score : compromis entre précision et rappel.
- ROC-AUC : capacité globale de discrimination indépendante du seuil.
- PR-AUC : particulièrement pertinente en présence de déséquilibres de classes.

La ROC-AUC mesure la capacité du modèle à classer correctement une observation maligne au-dessus d'une observation bénigne.

La PR-AUC (Precision-Recall AUC) est complémentaire : elle se concentre davantage sur la performance pour la classe positive et devient particulièrement informative lorsque la classe d'intérêt est minoritaire.

L'utilisation conjointe de ces métriques permet une évaluation plus complète et plus robuste.

4. Modèles classiques étudiés

Afin d'évaluer différentes hypothèses de modélisation, trois modèles de classification supervisée ont été implémentés :

- La régression logistique,
- L'arbre de décision,
- La forêt aléatoire.

Ces modèles couvrent des niveaux de complexité croissants et reposent sur des hypothèses structurelles différentes.

4.1 Régression logistique

La régression logistique est un modèle linéaire probabiliste qui estime la probabilité d'appartenance à la classe maligne via une fonction sigmoïde appliquée à une combinaison linéaire des variables explicatives.

Sa frontière de décision est linéaire dans l'espace des features. Cela signifie que si les classes sont approximativement séparables par une hyperplane, ce modèle peut obtenir d'excellentes performances.

Les résultats en validation croisée montrent :

- ROC-AUC moyenne : 0.9958
- F1-score moyen : 0.9640
- PR-AUC moyenne : 0.9949

La faible variabilité entre les folds indique une grande stabilité du modèle. Ces performances suggèrent que la structure des données est fortement discriminante et que la séparation entre les classes est proche d'un cadre linéaire.

Ce résultat est cohérent avec l'EDA, qui a mis en évidence des différences marquées entre les distributions des variables selon la classe.

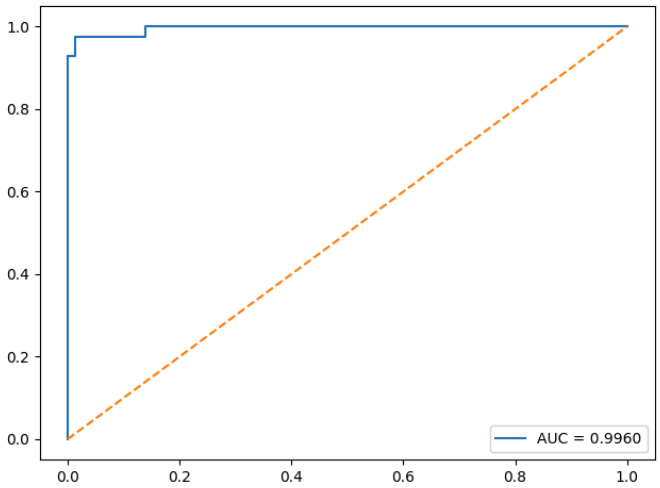

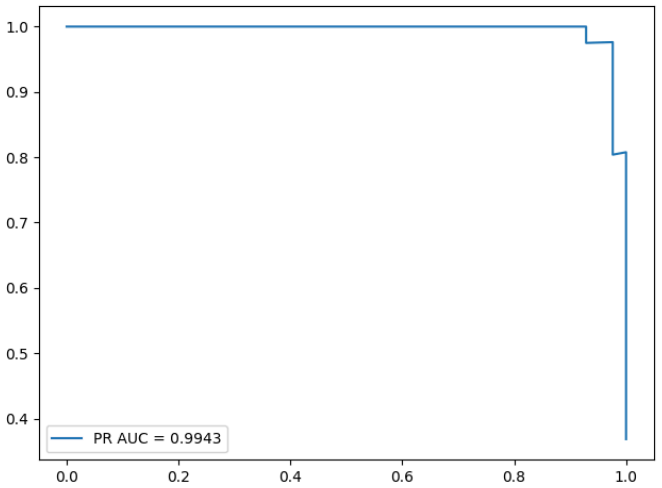

4.2 Arbre de décision

L'arbre de décision repose sur un partitionnement hiérarchique de l'espace des variables. Contrairement à la régression logistique, il est capable de modéliser des relations non linéaires et des interactions complexes entre variables.

Cependant, les résultats obtenus sont plus modestes :

- ROC-AUC moyenne : 0.9172
- F1-score moyen : 0.8962

La variabilité observée entre les folds est plus élevée, ce qui suggère une sensibilité accrue aux fluctuations de l'échantillon d'entraînement. Les arbres non régularisés sont connus pour présenter une forte variance et un risque de surapprentissage.

Dans ce cas précis, l'augmentation de flexibilité ne se traduit pas par un gain de performance, ce qui renforce l'hypothèse d'une structure de données relativement simple.

4.3 Forêt aléatoire

La forêt aléatoire est une méthode d'ensemble qui agrège un grand nombre d'arbres entraînés sur des sous-échantillons bootstrap des données et sur des sous-ensembles aléatoires de variables.

Ce mécanisme permet de réduire la variance inhérente aux arbres individuels tout en conservant leur capacité à modéliser des relations non linéaires.

Les performances obtenues sont élevées :

- ROC-AUC moyenne : 0.9877
- F1-score moyen : 0.9461
- PR-AUC moyenne : 0.9865

Bien que légèrement inférieures à celles de la régression logistique, ces performances restent robustes. Cela indique que l'ajout de complexité non linéaire n'apporte pas un avantage significatif sur ce dataset.

5. Validation croisée et comparaison approfondie des performances

La validation croisée stratifiée à cinq folds permet d'obtenir une estimation robuste des performances sur le jeu d'entraînement. Contrairement à un simple découpage unique, cette approche évalue la stabilité des modèles face à différentes partitions des données.

Les résultats montrent une hiérarchie claire :

1. Régression logistique : meilleure performance moyenne et très faible variance.
2. Forêt aléatoire : performance élevée mais légèrement inférieure.
3. Arbre de décision : performance plus faible et variabilité plus importante.

La très forte ROC-AUC obtenue par la régression logistique suggère que la séparation entre les classes est quasiment linéaire dans l'espace des variables. Autrement dit, la structure intrinsèque des données ne nécessite pas une frontière de décision fortement non linéaire.

La faible variabilité des scores entre les folds constitue un indicateur important : le modèle ne dépend pas fortement d'un sous-échantillon particulier. Cela renforce l'hypothèse d'une bonne capacité de généralisation.

6. Approche d'ensemble : Soft Voting

Afin d'explorer la possibilité d'améliorer les performances via la combinaison de modèles complémentaires, une approche de **soft voting manuel** a été implémentée.

Le principe consiste à :

- entraîner plusieurs modèles indépendants,
- moyenner leurs probabilités prédites,
- appliquer un seuil de décision sur la probabilité moyenne.

L'intérêt théorique d'une méthode d'ensemble repose sur la réduction de la variance et la compensation d'erreurs spécifiques à chaque modèle. Si les modèles commettent des erreurs différentes, leur combinaison peut améliorer la performance globale.

Les résultats montrent :

- ROC-AUC moyenne : 0.9946
- F1-score moyen : 0.9699

L'amélioration par rapport à la régression logistique seule reste marginale. Cela suggère que le modèle linéaire capture déjà l'essentiel de la structure discriminante des données. L'apport d'un modèle non linéaire n'apporte qu'une correction mineure.

Ce résultat est cohérent avec l'analyse précédente : lorsque les données sont fortement séparables de manière linéaire, les ensembles complexes n'apportent qu'un gain limité.

Il est important de noter que l'implémentation du soft voting a été réalisée manuellement afin de comprendre précisément le mécanisme de combinaison probabiliste et d'éviter une utilisation aveugle des fonctions prédéfinies.

7. Optimisation des hyperparamètres

Une recherche manuelle d'hyper paramètres a été réalisée pour l'arbre de décision, notamment sur :

- La profondeur maximale,
- Le nombre minimal d'observations pour effectuer un split.

L'objectif était d'évaluer si la performance plus faible du modèle provenait d'un mauvais réglage ou d'une limitation structurelle.

Le meilleur modèle retenu correspond à un arbre non limité en profondeur avec un minimum de cinq observations par split. La ROC-AUC obtenue en validation croisée atteint 0.9285.

Malgré cette amélioration par rapport au modèle initial, les performances restent inférieures à celles des autres approches. Cela indique que la limite observée provient principalement du compromis biais / variance inhérent à l'algorithme plutôt que d'un simple mauvais paramétrage.

Cette étape confirme l'importance de la phase d'optimisation, mais également le fait qu'un algorithme ne peut dépasser certaines limites imposées par sa structure.

8. Modèle de Deep Learning (MLP)

Un réseau de neurones multicouche (MLP) a été implémenté afin d'explorer une approche plus flexible et potentiellement capable de modéliser des interactions complexes entre variables.

L'architecture comprend :

- Une couche d'entrée correspondant au nombre de variables explicatives,
- Deux couches cachées de 64 puis 32 neurones,
- Des fonctions d'activation ReLU,
- Un mécanisme de dropout (p=0.2) pour limiter le surapprentissage,
- Une couche de sortie à un neurone avec fonction sigmoïde implicite via la fonction de perte.

L'entraînement repose sur :

- La fonction de perte BCEWithLogitsLoss adaptée à la classification binaire,
- L'optimiseur Adam,
- Un mécanisme de early stopping basé sur la perte de validation.

La courbe d'apprentissage montre une convergence stable et progressive, avec une diminution parallèle de la perte d'entraînement et de validation, indiquant l'absence de surapprentissage massif.

Cependant, malgré cette convergence correcte, le réseau de neurones ne surpasse pas les meilleurs modèles classiques. Plusieurs explications peuvent être avancées :

1. La taille modérée du dataset limite la capacité d'apprentissage d'architectures plus complexes.
2. Les données semblent déjà quasi-linéairement séparables.
3. L'augmentation de complexité n'apporte pas d'information supplémentaire exploitable.

Ce résultat illustre un principe fondamental du machine learning : une architecture plus complexe n'implique pas nécessairement une meilleure performance, en particulier lorsque la structure des données est simple.

9. Évaluation finale sur le jeu de test

L'évaluation finale est réalisée sur le jeu de test indépendant, resté strictement isolé pendant l'ensemble des phases d'entraînement, de validation croisée et d'optimisation.

Cette étape constitue la mesure la plus réaliste de la capacité de généralisation du modèle.

La régression logistique obtient sur le jeu de test :

- Accuracy : 0.9649

- F1-score : 0.9512
- Recall (classe maligne) : 0.9286
- ROC-AUC : 0.9960
- PR-AUC : très proche de 1

La matrice de confusion indique :

- 3 faux négatifs
- 1 faux positif

Dans un contexte médical, la minimisation des faux négatifs est prioritaire. Un rappel élevé signifie que la grande majorité des tumeurs malignes sont correctement détectées. La très forte ROC-AUC confirme la capacité discriminante exceptionnelle du modèle, indépendamment du seuil choisi.

La forêt aléatoire obtient une accuracy légèrement supérieure (0.9737), mais une ROC-AUC légèrement inférieure à celle de la régression logistique. L'arbre de décision reste en retrait, confirmant les observations faites en validation croisée.

Au regard :

- De la stabilité observée,
- De la simplicité du modèle,
- De son interprétabilité,
- Et de ses performances très élevées,

La régression logistique est retenue comme meilleur modèle classique.

Modèle	Accuracy	F1-score	Recall	ROC-AUC	PR-AUC	Confusion Matrix
Logistic Regression	0.965	0.951	0.929	0.996	0.994	[[71, 1], [3, 39]]
Decision Tree	0.930	0.905	0.905	0.925	0.854	[[68, 4], [4, 38]]
Random Forest	0.974	0.963	0.929	0.994	0.991	[[72, 0], [3, 39]]
MLP	0.982	0.976	0.976	0.997	0.995	—

10. Discussion critique

Les performances obtenues sont particulièrement élevées, avec une ROC-AUC proche de 1. Cette performance suggère que les classes sont fortement séparables dans l'espace des variables.

Le fait qu'un modèle linéaire obtienne les meilleurs résultats indique que la frontière de décision nécessaire est essentiellement linéaire. Dans ce contexte, l'augmentation de complexité apportée par des modèles non linéaires ou par un réseau de neurones ne génère pas de gain significatif.

Ce résultat illustre un principe fondamental du machine learning : la complexité d'un modèle doit être adaptée à la structure des données. Un modèle trop complexe peut introduire une variance inutile sans améliorer la performance.

Cependant, plusieurs limites doivent être soulignées :

1. Le dataset est relativement petit (569 observations).
2. Les données proviennent d'un contexte expérimental contrôlé.
3. Aucune validation externe sur un autre jeu de données n'a été réalisée.

Une évaluation sur des données issues d'un environnement clinique réel serait nécessaire pour confirmer la capacité de généralisation du modèle.

Par ailleurs, bien que les performances soient très élevées, un modèle déployé en pratique devrait être intégré dans un cadre décisionnel médical plus large, incluant l'expertise clinique et d'autres examens complémentaires.

11. Reproductibilité et bonnes pratiques

Le projet respecte les standards méthodologiques modernes du machine learning :

- Séparation stricte entre EDA et modélisation.
- Pipeline de preprocessing intégré.
- Absence de fuite d'information.
- Validation croisée stratifiée.
- Optimisation d'hyper paramètres.
- Comparaison d'approches classiques et deep learning.
- Implémentation personnalisée (soft voting manuel).
- Sauvegarde automatique des métriques et des modèles.
- Reproductibilité complète via une graine aléatoire fixe.
- Exécution en une seule commande via le script principal.

Les données sont récupérées dynamiquement, ce qui évite toute dépendance à un fichier local spécifique. L'ensemble du pipeline est modulaire et conforme aux standards professionnels.

Cette rigueur garantit que les résultats obtenus sont traçables, reproductibles et scientifiquement défendables.

Conclusion générale

Ce projet avait pour objectif de développer un pipeline complet de classification supervisée capable de prédire le caractère malin ou bénin d'une tumeur mammaire à partir de caractéristiques morphologiques.

Au-delà de la performance brute, l'enjeu principal était méthodologique : construire une démarche rigoureuse, reproductible et conforme aux standards actuels du machine learning.

Les résultats obtenus sont particulièrement solides :

- La régression logistique atteint une ROC-AUC de 0.9960 sur le jeu de test.
- Le nombre de faux négatifs est très limité.
- Les approches plus complexes n'apportent pas d'amélioration significative.

Ce constat montre qu'une augmentation de complexité algorithmique n'est pas systématiquement synonyme de meilleure performance. Lorsque les données sont fortement structurées et séparables, un modèle linéaire bien régularisé peut être optimal.

Le projet met en évidence l'importance :

- De l'analyse exploratoire,
- De la validation rigoureuse,
- De la prévention du data leakage,
- De l'interprétation critique des résultats.

Le pipeline développé constitue une base robuste, claire et reproductible, adaptée à un contexte académique et potentiellement transposable à des applications plus larges sous réserve d'une validation externe.

En conclusion, ce travail démontre qu'il est possible de combiner performance élevée, simplicité du modèle et discipline méthodologique, tout en conservant une interprétabilité et une stabilité importantes.